

Εθνικό Μετσόβιο Πολυτεχνείο

Σχολή Ηλεκτρολόγων Μηχανικών & Μηχανικών Υπολογιστών

Συστήματα Λήψης και Απόφασης

Εξαμηνιαία Εργασία

Physically Interpretable World Models

Four Principles for Physically Interpretable World Models

Αναπαραγωγή, Αξιολόγηση & Επεκτάσεις

Τελική Παρουσίαση

Ακαδημαϊκό έτος 2025-2026

Ιούνιος 2026

Σύνοψη Paper: Φυσική Ερμηνευσιμότητα στα World Models

Τα World Models μαθαίνουν τη δυναμική του περιβάλλοντος από pixels, αλλά ο λανθάνων χώρος τους είναι συνήθως «μαύρο κουτί».

Το Πρόβλημα

- **Physically Informed:** Η φυσική γνώση εισάγεται ως loss regularizer, αλλά ο λανθάνων χώρος παραμένει αδιαφανής.
- Δεν υπάρχουν φυσικές εγγυήσεις, ούτε δυνατότητα άμεσης σύνδεσης με κλασικό έλεγχο (PID, MPC) ή τυπική επαλήθευση.

Η Προτεινόμενη Λύση (PIWM)

- Ο λανθάνων χώρος αποκτά **ρητό φυσικό νόημα** (π.χ. συγκεκριμένες διαστάσεις αντιστοιχούν σε θέση, γωνία, ταχύτητα).
- Επιτυγχάνεται αξιοπιστία, ευκολότερος εντοπισμός σφαλμάτων και άμεση διεπαφή με συστήματα ελέγχου.

Σύνοψη Paper: Οι Τέσσερις Αρχές Σχεδιασμού

Οι συγγραφείς προτείνουν 4 θεμελιώδεις αρχές για την κατασκευή φυσικά ερμηνεύσιμων μοντέλων:

Αρχή 1: Δομική Αποσύνδεση

Ιδέα: Διαχωρισμός του latent space σε φυσική κατάσταση z_{phys} και οπτικό στυλ z_{img} .

$$z = [E_{\text{phys}}(o), E_{\text{img}}(o)]$$

Αρχή 2: Equivariance & Invariance

Ιδέα: Οπτικές αλλαγές (π.χ. φωτισμός) δεν πρέπει να επηρεάζουν τη φυσική κατάσταση.

$$E(g \cdot o) \approx h \cdot E(o)$$

Αρχή 3: Πολυεπίπεδη Επίβλεψη

Ιδέα: Σύνδεση των διαστάσεων του z_{phys} με πραγματικά φυσικά μεγέθη μέσω πλήρους, ασθενούς ή αυτο-επίβλεψης.

Αρχή 4: Διαμέριση Εξόδου

Ιδέα: Ανεξάρτητοι αποκωδικοποιητές για διαφορετικά τμήματα της εικόνας, διευκολύνοντας την επαλήθευση.

Τα Αποτελέσματά μας: Στόχοι & Συνεισφορά

Η δική μας εργασία δεν περιορίζεται στην απλή αναπαραγωγή, αλλά επεκτείνει τη μεθοδολογία με άξονα την ευρωστία:

Αναβαθμίσεις & Διορθώσεις

- Διόρθωση σημαντικών ασυμβατοτήτων και ελλείψεων του αρχικού repository (π.χ. τυχαία συλλογή δεδομένων, διαστάσεις εικόνων).
- Σημαντική αναβάθμιση της αρχιτεκτονικής δυναμικής (LSTM) για σταθερότητα σε μεγάλο ορίζοντα.

Stress-Testing (OOD)

- **Καινοτομία:** Εισαγωγή οπτικών αλλοιώσεων εκτός κατανομής (OOD) για να ελέγξουμε τα όρια των αρχών.
- **Πειράματα:** Χωρικός θόρυβος (Gaussian noise) και μεταβολές φωτεινότητας (brightness jitter).

Τα Αποτελέσματά μας: Αναβαθμίσεις Αρχιτεκτονικής

Για τη βελτίωση της σταθερότητας κατά το rollout (π.χ. $h = 30$ βήματα), υλοποιήσαμε τις εξής αναβαθμίσεις:

Residual LSTMs

Αντικαταστήσαμε το απλό LSTM με Residual LSTM, όπου το δίκτυο προβλέπει τη μεταβολή της κατάστασης (Δz):

$$\hat{z}_{t+1} = z_t + \text{LSTM}(z_t, a_t; \theta)$$

Αποτρέπει την κατάρρευση των προβλέψεων σε βάθος χρόνου.

Στρατηγικές Εκπαίδευσης

- **Curriculum Learning:** Σταδιακή αύξηση του ορίζοντα εκπαίδευσης (h) από $1 \rightarrow 30$ βήματα.
- **Scheduled Sampling:** Εκθετική μείωση του teacher forcing κατά την εκπαίδευση, προετοιμάζοντας το μοντέλο για multi-step rollouts.


Τα Αποτελέσματά μας: Πειραματική Διάταξη

Περιβάλλοντα

- **CartPole:** $z_{\text{phys}} \in \mathbb{R}^4$ (θέση, ταχύτητα, γωνία, γων. ταχύτητα).
- **LunarLander:** $z_{\text{phys}} \in \mathbb{R}^8$ (θέση, ταχύτητες, γωνία, γων. ταχύτητα, επαφή ποδιών).

Δείκτες Αξιολόγησης


- **Robust Metrics:** Χρήση Διαμέσου (Median) και IQR λόγω heavy-tailed σφαλμάτων.
- **Statistical Testing:** Κατά ζεύγη διαφορά (Δ) με 95% Bootstrap Confidence Intervals ($N = 1000$ resamples).



Σχ. 1: Το περιβάλλον CartPole

Τα Αποτελέσματά μας: Αναπαραγωγή Clean (Αρχές 1 & 2)


- **Παρατήρηση:** Σε καθαρές συνθήκες ($\sigma = 0$), το Baseline και η Αρχή 2 έχουν ταυτόσημη, εξαιρετικά υψηλή ακρίβεια.
- Η Αρχή 1 εμφανίζει ελαφρώς μεγαλύτερο σφάλμα (State MSE).
- **Αιτιολογία:** Χωρίς οπτικές αλλοιώσεις, οι αρχιτεκτονικοί περιορισμοί (όπως το στενό bottleneck των 4 διαστάσεων της Αρχής 1) απλώς περιορίζουν τη χωρητικότητα του δικτύου.
- Επιβεβαιώνεται ότι οι αρχές δεν στοχεύουν στην ακρίβεια υπό ιδανικές συνθήκες, αλλά στην ευρωστία.



Σχ. 2: State MSE σε καθαρό περιβάλλον ($\sigma = 0.00$)

Τα Αποτελέσματά μας: Αναπαραγωγή Clean (Αρχή 3)


- **Παρατήρηση:** Υπό καθαρές συνθήκες, η πλήρης επίβλεψη (Baseline) δίνει το χαμηλότερο δυνατό σφάλμα.
- Η ασθενής επίβλεψη (P3-weak) ακολουθεί στενά.
- Η απουσία επίβλεψης ταχύτητας (P3-semi) οδηγεί σε σημαντική συσσώρευση σφάλματος κατά το rollout.
- **Συμπέρασμα:** Κάποια μορφή επίβλεψης ή φυσικής γνώσης για τις ταχύτητες είναι απαραίτητη για τη σταθεροποίηση της δυναμικής του World Model.



Σχ. 3: Αξιολόγηση Αρχής 3 σε καθαρό περιβάλλον ($\sigma = 0.00$)

Τα Αποτελέσματά μας: Ευρωστία σε Χωρικό Θόρυβο


- Η Αρχή 1 ως Δομικό Φίλτρο: Παρουσιάζει εξαιρετική ευρωστία. Ακόμα και σε έντονο θόρυβο ($\sigma = 0.30$), το MSE παραμένει χαμηλό.
- Ο διαχωρισμός του encoder εγκλωβίζει τον θόρυβο των pixels στον κλάδο του στυλ (z_{img}), προστατεύοντας τις φυσικές διαστάσεις (z_{phys}).
- Κατάρρευση της Αρχής 2: Η κανονικοποίηση equivariance αναγκάζει το μοντέλο να βασίζεται σε λεπτομερείς οπτικές δομές (ακμές). Όταν αυτές καταστρέφονται, ο encoder παράγει ακραίες OOD τιμές.



Σχ. 4: Ευρωστία σε Gaussian Noise ($h = 30$)

Τα Αποτελέσματά μας: Ευρωστία σε Φωτεινότητα

- **Η Αρχή 2 ως Ασπίδα Φωτισμού:** Όταν εφαρμόζεται μεταβολή φωτεινότητας, η Αρχή 2 υπερτερεί ξεκάθαρα του Baseline.
- **Στατιστική Επαλήθευση:** Η ανάλυση paired bootstrap δείχνει ότι η διαφορά $\Delta = \text{Baseline} - \text{Principle 2}$ είναι σταθερά θετική με 95% διάστημα εμπιστοσύνης.
- **Εξήγηση:** Η ρητή κανονικοποίηση αναγκάζει τον encoder να αγνοεί τις ομοιόμορφες μεταβολές χρώματος/φωτισμού, διατηρώντας αναλλοίωτη τη φυσική κατάσταση.



Σχ. 5: Paired Difference υπό Brightness Jitter

Τα Αποτελέσματά μας: Ασθενής Επίβλεψη υπό Θόρυβο

Το Παράδοξο της Αρχής 3

- Υπό την παρουσία χωρικού θορύβου, το μοντέλο με ασθενή επίβλεψη (P3-weak) **υπερτερεί** του πλήρως επιβλεπόμενου Baseline!
- **Εξήγηση:** Η εκπαίδευση με «θορυβώδεις» εκτιμήσεις ταχυτήτων (μέσω πεπερασμένων διαφορών) λειτούργησε ως έμμεση κανονικοποίηση (implicit regularizer).
- Απέτρεψε τον encoder από το να κάνει overfit στις τέλειες, καθαρές λεπτομέρειες των δεδομένων εκπαίδευσης, αυξάνοντας τη γενίκευση σε noisy OOD καταστάσεις.

Συμπέρασμα

Η απαίτηση για τέλεια δεδομένα επίβλεψης είναι μύθος. Η προσεγγιστική, ασθενής επίβλεψη φυσικών μεγεθών όχι μόνο επαρκεί, αλλά καθιστά το μοντέλο πιο εύρωστο σε συνθήκες εκτός κατανομής.

Αποτίμηση

- **Αποσύνδεση (Αρχή 1):** Η ασφαλέστερη επιλογή για γενικό χωρικό θόρυβο.
- **Equivariance (Αρχή 2):** Εξαιρετική για συγκεκριμένες μεταβολές (φωτισμός), αλλά εύθραυστη σε θόρυβο pixel.
- **Ασθενής Επίβλεψη (Αρχή 3):** Προσφέρει regularizing effect OOD.

Μελλοντικές Επεκτάσεις

- **Φυσικοί Κανόνες από LLMs:** Χρήση μεγάλων γλωσσικών μοντέλων για τον αυτόματο εντοπισμό και ορισμό κανόνων equivariance/invariance.
- **Σύνδεση με Έλεγχο:** Πραγματική ενσωμάτωση του ερμηνεύσιμου z_{phys} σε ελεγκτές MPC για ασφαλές planning.

Κατανομή Εργασιών & Ρόλοι Μελών

Μέλος Ομάδας	AM	Ρόλος & Συνεισφορά στην Εργασία
Πλουμής Φίλιππος	03122115	Συλλογή δεδομένων, pipeline μεταφοράς στα μοντέλα.
Ρήγας Αθανάσιος	03122078	VAE/LSTM updates, Scheduled Sampling, Curriculum Learning.
Μπακογιώργος Ηλίας	03122019	Υλοποίηση Αρχής 1 (disentanglement) & Αρχής 2 (equivariance).
Φειδάκης Αθανάσιος	03122676	Υλοποίηση Αρχής 3 (supervision), Αρχής 4 & paired bootstrap eval.

Συνεργασία

Όλα τα μέλη συμμετείχαν εξίσου στη θεωρητική μελέτη του άρθρου, στο σχεδιασμό των OOD stress-tests, στη συγγραφή της τελικής αναφοράς και στην προετοιμασία της παρουσίασης.

Retrospective: Τι μας δυσκόλεψε

Τι μας δυσκόλεψε

- **Ποιότητα Αρχικού Κώδικα:** Ο κώδικας του paper ήταν εξαιρετικά ελλιπής, χωρίς scheduled sampling ή curriculum, αναγκάζοντάς μας να ξαναγράψουμε μεγάλο μέρος του.
- **Multi-Objective Loss:** Η ισορροπία μεταξύ ανακατασκευής (ELBO), equivariance (loss) και επίβλεψης ήταν πολύ ευαίσθητη και απαιτούσε επίπονο tuning.

Τι θα κάναμε καλύτερα

- **Automated Hyperparameter Tuning:** Χρήση βιβλιοθηκών (π.χ. Optuna) για την αυτόματη εύρεση των βαρών λ της απώλειας.
- **Νωρίτερη OOD Αξιολόγηση:** Αν είχαμε εισάγει το θόρυβο νωρίτερα, θα είχαμε εντοπίσει τις αδυναμίες της Αρχής 2 πριν επενδύσουμε χρόνο στο setup της.

Ευχαριστούμε για την προσοχή σας. Είμαστε στη διάθεσή σας για ερωτήσεις.