

Interpretable World Models Principles

Φ. Πλουμής Α. Ρήγας Η. Μπακογιώργος Α. Φειδάκης
Σχολή Ηλεκτρολόγων Μηχανικών & Μηχανικών Υπολογιστών
Εθνικό Μετσόβιο Πολυτεχνείο, Αθήνα

Περίληψη Η παρούσα εργασία παρουσιάζει την αναπαραγωγή και εκτεταμένη αξιολόγηση των αρχών σχεδιασμού για World Models (PIWM). Ενώ η αρχική μελέτη περιορίστηκε σε καθαρά περιβάλλοντα, η υλοποίησή μας αναβαθμίζει την αρχιτεκτονική (χρήση residual LSTMs, curriculum learning, scheduled sampling) και εξετάζει την ευρωστία των μοντέλων σε συνθήκες εκτός κατανομής (Out-of-Distribution, OOD), όπως χωρικός θόρυβος και μεταβολές φωτεινότητας. Τα πειράματα στα περιβάλλοντα CartPole και LunarLander αναδεικνύουν άγνωστους περιορισμούς: η Αρχή 1 (αποσύνδεση αναπαραστάσεων) λειτουργεί ως ισχυρό φίλτρο χωρικού θορύβου, η Αρχή 2 (equivariance) καταρρέει υπό τυχαίο θόρυβο αλλά διαπρέπει σε μεταβολές φωτεινότητας, ενώ η Αρχή 3 (ασθενής επίβλεψη) λειτουργεί ως έμμεση κανονικοποίηση, καθιστώντας το μοντέλο πιο ανθεκτικό από τα πλήρως επιβλεπόμενα baselines. Υλοποιούμε επίσης την Αρχή 4 (διαμέριση εξόδου), επιτυγχάνοντας μείωση των παραμέτρων του decoder κατά 75% χωρίς απώλεια ποιότητας. Τέλος, ως επέκταση πέρα από το αρχικό άρθρο, αντικαθιστούμε το «μαύρο κουτί» LSTM με αραιή ταυτοποίηση δυναμικής (SINDy), η οποία ανακτά ρητές, ερμηνεύσιμες εξισώσεις κίνησης και επιδεικνύει σημαντικά μεγαλύτερη ευρωστία στον θόρυβο.

Λέξεις Κλειδιά World Models, Variational Autoencoders, LSTMs, Representation Learning, Out-of-Distribution Robustness

I . ΕΙΣΑΓΩΓΗ

Τα World Models επιτρέπουν σε πράκτορες να μαθαίνουν ένα λανθάνον (latent) μοντέλο δυναμικής του περιβάλλοντός τους. Η πρόσφατη βιβλιογραφία (PIWM) προτείνει τέσσερις αρχές σχεδιασμού για την ενσωμάτωση φυσικής γνώσης: (1) αποσύνδεση φυσικής και οπτικής κατάστασης, (2) επιβολή ισοδυναμίας (equivariance) σε μετασχηματισμούς, (3) ασθενή επίβλεψη ταχύτητας, και (4) διαμέριση του decoder ανά αντικείμενο της σκηνής.

Στην παρούσα εργασία, δεν αναπαράγουμε απλώς τα αποτελέσματα, αλλά επεκτείνουμε τη μεθοδολογία. Εντοπίσαμε ότι ο κώδικας της αρχικής δημοσίευσης υστερούσε σε σταθερότητα κατά το rollout. Εισάγουμε μια αναβαθμισμένη αρχιτεκτονική και, το σημαντικότερο, εισάγουμε OOD παρεμβολές (Gaussian/Salt & Pepper noise, brightness jitter). Αποδεικνύουμε ότι οι αρχές αυτές δεν προσφέρουν πλεονέκτημα σε καθαρά περιβάλλοντα (όπου το Baseline υπερτερεί λόγω μεγαλύτερης χωρητικότητας), αλλά αποτελούν στοχευμένους μηχανισμούς άμυνας ενάντια σε συγκεκριμένες οπτικές αλλοιώσεις. Ως επέκταση πέρα από το άρθρο, αντικαθιστούμε το LSTM με αραιή ταυτοποίηση δυναμικής (SINDy), δείχνοντας ότι ο φυσικός ερμηνεύσιμος λανθάνων χώρος επιτρέπει την εξαγωγή ρητών εξισώσεων κίνησης με αυξημένη ευρωστία.

II . ΜΕΘΟΔΟΛΟΓΙΑ ΚΑΙ ΥΛΟΠΟΙΗΣΗ

Η προτεινόμενη αρχιτεκτονική υλοποιεί ένα μοντέλο two-stage. Αρχικά, ένας Variational Autoencoder (VAE) χρησιμοποιείται για την εξαγωγή συμπαγών λανθανόντων χαρακτηριστικών z_t από υψηλής διάστασης οπτικές παρατηρήσεις o_t . Στη συνέχεια, ένα αναδρομικό νευρωνικό δίκτυο (LSTM) αναλαμβάνει την πρόβλεψη της μελλοντικής δυναμικής $\hat{z}_{t+1} = f(z_t, a_t)$, δεδομένης της τρέχουσας κατάστασης και της δράσης a_t του πράκτορα.

A'. Αναβαθμίσεις Αρχιτεκτονικής Δυναμικής (LSTM)

Για να αποτρέψουμε την κατάρρευση των προβλέψεων σε μεγάλους ορίζοντες (π.χ. $h = 30$), υλοποιήσαμε Residual LSTMs, όπου το δίκτυο μαθαίνει τη μεταβολή της κατάστασης:

$$\hat{z}_{t+1} = z_t + \text{LSTM}(z_t, a_t; \theta) \quad (1)$$

Επιπλέον, ενσωματώσαμε Curriculum Learning (σταδιακή αύξηση του ορίζοντα εκπαίδευσης) και Scheduled Sampling (εκθετική μείωση του teacher forcing), στοιχεία που απουσίαζαν από την αρχική υλοποίηση.

B'. Αρχή 1: Αποσύνδεση (Disentanglement)

Η Αρχή 1 επιβάλλει τη δομική αποσύνδεση του VAE σε έναν encoder για τη φυσική κατάσταση $z_{\text{phys}} \in \mathbb{R}^k$ (π.χ. $k = 4$ για το CartPole) και έναν για το οπτικό στυλ z_{img} . Η συνάρτηση απώλειας περιλαμβάνει την τυπική ELBO, με την επιπλέον συνθήκη ότι η ανακατασκευή χρησιμοποιεί τον διαχωρισμένο χώρο.

Γ'. Αρχή 2: Ισοδυναμία (Equivariance)

Η Αρχή 2 χρησιμοποιεί έναν ενιαίο/μονολιθικό encoder (όπως το Baseline) αλλά επιβάλλει κανονικοποίηση ισοδυναμίας. Αν g είναι ένας μετασχηματισμός στην εικόνα (π.χ. αλλαγή φωτεινότητας) και h ο αντίστοιχος μετασχηματισμός στον λανθάνοντα χώρο, ελαχιστοποιείται η απόσταση:

$$\mathcal{L}_{\text{eq}} = \mathbb{E}_{o \sim D} [\|E(g \cdot o) - h \cdot E(o)\|_2^2] \quad (2)$$

Στην περίπτωση της φωτεινότητας, το h είναι ο ταυτοτικός μετασχηματισμός (invariance).

Δ'. Αρχή 3: Ασθενής Επίβλεψη (Weak Supervision)

Συχνά η πραγματική ταχύτητα (velocity) δεν είναι διαθέσιμη. Υλοποιήσαμε την Αρχή 3 υπολογίζοντας προσεγγιστικές ταχύτητες μέσω πεπερασμένων διαφορών:

$$v_t \approx \frac{x_{t+1} - x_t}{\Delta t} \quad (3)$$

Αυτές οι «θορυβώδεις» εκτιμήσεις χρησιμοποιούνται για την επίβλεψη των διαστάσεων ταχύτητας στον λανθάνοντα χώρο.

Ε'. Αρχή 4: Διαμέριση Εξόδου (Compositional Decoding)

Αντί ενός μονολιθικού decoder, η Αρχή 4 χρησιμοποιεί ανεξάρτητους αποκωδικοποιητές ανά αντικείμενο της σκηνής (π.χ. cart, pole, background), των οποίων οι έξοδοι συντίθενται στην τελική εικόνα. Η διάσπαση αυτή μειώνει δραστηρικά τις παραμέτρους του decoder και επιτρέπει την επαλήθευση ανά συνιστώσα.

Γ'. Επέκταση: Ερμηνεύσιμη Δυναμική με SINDy

Πέρα από το αρχικό άρθρο, εξετάζουμε αν η δυναμική του (φυσικά εποπτεύμενου) λανθάνοντος χώρου μπορεί να ταυτοποιηθεί ρητά. Εφαρμόζουμε SINDyC (Sparse Identification of Nonlinear Dynamics with control) [3] στις φυσικές διαστάσεις, μαθαίνοντας έναν αραιό πίνακα συντελεστών Ξ πάνω σε μια βιβλιοθήκη υποψήφιων συναρτήσεων $\Theta(z, u)$ (πολυώνυμα, τριγωνομετρικοί όροι, συζεύξεις ελέγχου):

$$\hat{z}_{t+1} = z_t + \Theta(z_t, u_t) \Xi, \quad (4)$$

όπου το Ξ προκύπτει μέσω Sequentially Thresholded Least Squares (STLSQ). Δοκιμάζουμε επίσης ένα gray-box hybrid, όπου ένα υπολειμματικό LSTM διορθώνει το (παγωμένο) SINDy: $\hat{z}_{t+1} = z_t + \Theta(z_t, u_t) \Xi + \text{LSTM}(z_t, a_t)$.


III . ΠΕΙΡΑΜΑΤΙΚΗ ΔΙΑΤΑΞΗ

Τα πειράματα διεξήχθησαν σε δύο περιβάλλοντα: το κλασικό CartPole και το πιο πολύπλοκο LunarLander. Λόγω της heavy-tail κατανομής των σφαλμάτων πρόβλεψης σε μεγάλους ορίζοντες, η αξιολόγηση έγινε χρησιμοποιώντας δείκτες ευρωστίας: διάμεσο (Median) και ενδοτεταρτημοριακό εύρος (IQR). Για τη σύγκριση μοντέλων (A vs B), υπολογίσαμε την κατά ζεύγη διαφορά (Paired Difference) $\Delta = \text{MSE}_A - \text{MSE}_B$ με 95% Bootstrap Confidence Intervals ($N = 1000$ resamples).

IV . ΑΠΟΤΕΛΕΣΜΑΤΑ

Α'. Αξιολόγηση σε Καθαρά Περιβάλλοντα


Σε περιβάλλοντα χωρίς οπτικό θόρυβο ($\sigma = 0$), το απλό Baseline μοντέλο τείνει να υπερτερεί ή να ισοβαθμεί με τις Αρχές 1 και 2. Όπως φαίνεται στο Σχήμα 1, η μέση τετραγωνική απόσταση (State MSE) για το Baseline και την Αρχή 2 είναι εξαιρετικά χαμηλή και σχεδόν ταυτόσημη. Αντίθετα, η Αρχή 1 παρουσιάζει ελαφρώς μεγαλύτερο σφάλμα. Αυτό εξηγείται διότι, χωρίς distractors, οι αρχιτεκτονικοί περιορισμοί (όπως το στενό bottleneck των 4 διαστάσεων της Αρχής 1) απλώς περιορίζουν τη χωρητικότητα του δικτύου. Αυτό επιβεβαιώνει ότι οι αρχές του PIWM δεν προσφέρουν απαραίτητα βελτίωση της ακρίβειας σε ιδανικές συνθήκες, αλλά αποσκοπούν στην ευρωστία.



Σχήμα 1. Αναπαραγωγή των αποτελεσμάτων του PIWM σε απόλυτα καθαρό περιβάλλον (encoded state, $\sigma = 0.00$). Τα μοντέλα Baseline και Αρχή 2 ταυτίζονται σχεδόν απόλυτα, ενώ η Αρχή 1 εμφανίζει ελαφρώς χειρότερη απόδοση λόγω δομικών περιορισμών.

Β'. Αρχή 1: Δομικό Φίλτρο Χωρικού Θορύβου

Κατά την εισαγωγή Gaussian noise, η Αρχή 1 επέδειξε εντυπωσιακή ευρωστία. Σε ορίζοντα προβλέψεων $h = 30$ και έντονο θόρυβο $\sigma = 0.30$, το MSE της Αρχής 1 διατηρήθηκε σε χαμηλά επίπεδα, εν αντιθέσει με το Baseline και την Αρχή 2 που παρουσίασαν πλήρη κατάρρευση (βλ. Σχήμα 2).




Σχήμα 2. Αξιολόγηση ευρωστίας (State MSE) σε διαφορετικά επίπεδα Gaussian Noise για το περιβάλλον CartPole. Διακρίνεται η υπεροχή της Αρχής 1 (πορτοκαλί καμπύλη) σε υψηλά επίπεδα θορύβου.

Η συμπεριφορά αυτή εξηγείται θεωρητικά από τη δομή του VAE. Ο διαχωρισμός του encoder δρα ως φυσικό φίλτρο: ο μη-δομημένος θόρυβος των pixels αδυνατεί να βρει συσχέτιση με τις παραμέτρους της δυναμικής του συστήματος και εγκλωβίζεται σχεδόν εξ ολοκλήρου στον encoder του στυλ (z_{img}). Ως αποτέλεσμα, δεν «μολύνει» τις φυσικές διαστάσεις (z_{phys}), προστατεύοντας τις προβλέψεις του LSTM.

Γ'. Αρχή 2: Το Κόστος της Κανονικοποίησης

Τα πειράματά μας αποκάλυψαν τον διττό χαρακτήρα της Αρχής 2. Από τη μία πλευρά, διαπρέπει απέναντι σε συστηματικές αλλαγές φωτεινότητας (brightness jitter). Όπως φαίνεται στο Σχήμα 3, η στατιστική ανάλυση bootstrap της κατά ζεύγη διαφοράς (Paired Difference) επιβεβαιώνει με 95% διάστημα εμπιστοσύνης ότι η Αρχή 2 υπερτερεί σταθερά του Baseline σε αυτά τα πειράματα.

Από την άλλη πλευρά, ωστόσο, η Αρχή 2 αποτυγχάνει παταγωδώς υπό χωρικό θόρυβο. Εικάζουμε ότι η ισχυρή




Σχήμα 3. Ανάλυση Paired Difference ($\Delta = \text{Baseline} - \text{Principle 2}$) υπό συνθήκες Brightness Jitter. Η θετική διαφορά επιβεβαιώνει την ανωτερότητα της Αρχής 2.

κανονικοποίηση equivariance αναγκάζει το μοντέλο να εστιάζει υπερβολικά στις ακριβείς ακμές και στις χωρικές οπτικές δομές της εικόνας για να ικανοποιήσει την εξίσωση (2). Όταν αυτές οι δομές καταστρέφονται από τυχαίο θόρυβο επιπέδου pixel, ο μονολιθικός encoder αδυνατεί να γενικεύσει και παράγει ακραίες OOD αναπαραστάσεις, αποσταθεροποιώντας πλήρως το LSTM.


Δ'. Αρχή 3: Η Ατέλεια ως Κανονικοποίηση (Implicit Regularization)

Στην περίπτωση της Αρχής 3, παρατηρήσαμε ένα παράδοξο. Σε καθαρά περιβάλλοντα (Σχήμα 4), το πλήρως επιβλεπόμενο Baseline τείνει να υπερτερεί έναντι των μοντέλων με ασθενή επίβλεψη (P3-weak) ή μερική επίβλεψη (P3-semi).



Σχήμα 4. Αναπαραγωγή αποτελεσμάτων της Αρχής 3 σε καθαρό περιβάλλον ($\sigma = 0.00$). Το πλήρως επιβλεπόμενο Baseline είναι το πιο ακριβές, ενώ η απουσία επίβλεψης ταχύτητας (P3-semi) οδηγεί σε μεγαλύτερο σφάλμα.

Ωστόσο, το μοντέλο P3-weak (ασθενής επίβλεψη μέσω πεπερασμένων διαφορών) αποδείχθηκε πιο ανθεκτικό στον οπτικό θόρυβο από το Baseline (Σχήμα 5). Καθώς εκπαιδεύτηκε με «θορυβώδεις» εκτιμήσεις ταχύτητας, ο λανθάνων χώρος του δεν έκανε overfit στην ψευδαίσθηση των τέλει δεδομένων, δρώντας ως implicit regularizer. Αντίθετα, το P3-semi (καμία επίβλεψη ταχύτητας) απέτυχε πλήρως υπό θόρυβο, επιβεβαιώνοντας ότι κάποια μορφή δυναμικής γνώσης είναι απαραίτητη.




Σχήμα 5. Αρχή 3 υπό Gaussian noise (CartPole). Σε μεγάλους ορίζοντες και υψηλό θόρυβο, η ασθενής επίβλεψη (P3-weak, κόκκινο) ξεπερνά το πλήρως επιβλεπόμενο Baseline (μπλε), δρώντας ως έμμεση κανονικοποίηση: η μερική επίβλεψη (P3-semi) αποτυγχάνει.

Ε'. Αρχή 4: Συμπύεση χωρίς Απώλεια Ποιότητας

Η συνθετική αποκωδικοποίηση επιβεβαίωσε τον ισχυρισμό του άρθρου. Στο CartPole, οι τρεις ανεξάρτητοι αποκωδικοποιητές μείωσαν τις παραμέτρους του decoder κατά **75.4%** (από 665k σε 164k) και τις συνολικές κατά 25.9%, διατηρώντας ουσιαστικά ταυτόσημη ποιότητα ανακατασκευής (Πίνακας I, Σχήμα 6). Η συνιστωσποιημένη έξοδος προσφέρει επιπλέον δυνατότητα επαλήθευσης ανά αντικείμενο, στοιχείο κρίσιμο για την ασφάλεια.

Πίνακας I
APXH 4: BASELINE Σ P4 ΣΤΟ CARTPOLE.

Metric	Baseline	P4
recon MSE ↓	0.00315	0.00306
SSIM ↑	0.9581	0.9582
decoder params ↓	665k	164k (-75.4%)



Σχήμα 6. Αρχή 4: GT vs baseline vs P4 (σύνθεση και επιμέρους αποκωδικοποιητές cart/pole/bg).

Α'. Ερμηνεύσιμη Δυναμική: SINDy vs LSTM

Η αραιή ταυτοποίηση ανέκτησε αυτόματα ερμηνεύσιμες εξισώσεις κίνησης με μόλις 12 μη-μηδενικούς όρους (από 88), συμπεριλαμβανομένων των κινηματικών ολοκληρωμάτων (π.χ. $x_{t+1} = x_t + 0.021 \dot{x}$, $\theta_{t+1} = \theta_t + 0.176 \dot{\theta}$) και του όρου βαρύτητας $\sin \theta$. Στην αξιολόγηση ευρωστίας (Πίνακας II), αν και σε καθαρές συνθήκες τα τρία μοντέλα

ισοβαθμούν, υπό έντονο θόρυβο ($\sigma = 0.30$) το SINDy υποβαθμίζεται μόλις $\times 3.7$ έναντι $\times 15$ του LSTM, επιβεβαιώνοντας ότι η ρητή φυσική δομή προσφέρει ευρωστία. Το gray-box hybrid επιτυγχάνει το χαμηλότερο σφάλμα σε καθαρές συνθήκες, αλλά με μη φραγμένη υπολειμματική διόρθωση κληρονομεί την ευθραυστότητα του LSTM στον θόρυβο.

Πίνακας II
ΕΥΡΩΣΤΙΑ ΔΥΝΑΜΙΚΗΣ ΣΕ GAUSSIAN NOISE (MEAN STATE MSE, BASELINE LATENT).

σ	LSTM	SINDy	Hybrid
0.00	0.033	0.035	0.027
0.10	0.085	0.045	0.075
0.30	0.509	0.130	0.441

V . ΣΥΖΗΤΗΣΗ

Τα ευρήματά μας υποδεικνύουν ότι ο σχεδιασμός World Models απαιτεί συμβιβασμούς (trade-offs). Η σκληρή αρχιτεκτονική δομή (Αρχή 1) είναι η ασφαλέστερη επιλογή απέναντι σε μη δομημένες αλλοιώσεις (π.χ. φθορά αισθητήρων). Η ρητή κανονικοποίηση (Αρχή 2) είναι εξαιρετικά ισχυρή αλλά ταυτόχρονα εύθραυστη αν το περιβάλλον παραβιάσει τις υποθέσεις της. Τέλος, η απαίτηση για τέλεια δεδομένα είναι μύθος: οι προσεγγιστικές μετρήσεις (Αρχή 3) μπορούν πρακτικά να βελτιώσουν την ικανότητα γενίκευσης του μοντέλου εκτός κατανομής.

VI . ΣΥΜΠΕΡΑΣΜΑΤΑ

Αναπτύξαμε ένα εύρωστο pipeline εκπαίδευσης και αξιολόγησης για Physics-Informed World Models. Μέσω αυστηρών OOD πειραμάτων, δεν αναπαράγαμε απλώς τη σχετική βιβλιογραφία, αλλά αποκαλύψαμε κρίσιμους, αδημοσίετους μηχανισμούς σχετικά με το πώς η αποσύνδεση, η ισοδυναμία και η ασθενής επίβλεψη συμπεριφέρονται κάτω από ρεαλιστικό αισθητηριακό θόρυβο. Επιπλέον, δείξαμε ότι η συνθετική αποκωδικοποίηση (Αρχή 4) συμπιέζει τον decoder κατά 75% χωρίς απώλεια ποιότητας, και ότι η αραιή ταυτοποίηση δυναμικής (SINDy) εξάγει ερμηνεύσιμες και εύρωστες εξισώσεις κίνησης, ανοίγοντας δρόμο προς δυναμικά μοντέλα που διατηρούν φυσικές εγγυήσεις (π.χ. Hamiltonian NNs). Τα αποτελέσματα αυτά προσφέρουν πρακτικές οδηγίες για την ανάπτυξη πραγματικών ρομποτικών συστημάτων.

ΑΝΑΦΟΡΕΣ

- [1] Original PIWM Authors, "World Model Principles", *Conference/Journal Name*, Year.
- [2] D. Ha and J. Schmidhuber, "World Models", *arXiv preprint arXiv:1803.10122*, 2018.
- [3] S. L. Brunton, J. L. Proctor, and J. N. Kutz, "Discovering governing equations from data by sparse identification of nonlinear dynamical systems", *PNAS*, vol. 113, no. 15, pp. 3932–3937, 2016.