

ΕΘΝΙΚΟ ΜΕΤΣΟΒΙΟ ΠΟΛΥΤΕΧΝΕΙΟ

Σχολή Ηλεκτρολόγων Μηχανικών και Μηχανικών Υπολογιστών

Εξαμηνιαία Εργασία

Four Principles for Physically Interpretable World Models

Αναπαραγωγή, αξιολόγηση και πιθανές επεκτάσεις

Τελική Παρουσίαση

Πλουμής Φίλιππος, Ρήγας Αθανάσιος, Μπακογιώργος Ηλίας, Φειδάκης Αθανάσιος

Αθήνα · Ιούνιος 2026

Physically Interpretable World Models (PIWM)

Γιατί χρειαζόμαστε λανθάνοντα χώρο με ρητό φυσικό νόημα

Το πρόβλημα

- **World Models:** παραγωγικά μοντέλα που μαθαίνουν να προβλέπουν την εξέλιξη ενός περιβάλλοντος σε συμπιεσμένο λανθάνοντα χώρο.
- **Σημασία:** κρίσιμα για σχεδιασμό & αυτόνομη πλοήγηση μέσω «ονείρου» (dreaming) του μέλλοντος.
- **Black-box latent:** οι κλασικές αναπαραστάσεις είναι αδιαφανείς — καμία διάσταση δεν αντιστοιχεί σε φυσικό μέγεθος.
- **Συνέπεια:** δύσκολος έλεγχος, χαμηλή αξιοπιστία, κακή γενίκευση σε θόρυβο/OOD.

Η προσέγγιση του paper & ο στόχος μας

- **PIWM:** κάθε διάσταση του latent αποκτά ρητό φυσικό νόημα (θέση, ταχύτητα, γωνία...).
- **4 αρχές σχεδίασης** που οργανώνουν, ευθυγραμμίζουν και επιβλέπουν τον λανθάνοντα χώρο.
- **Στόχος εργασίας:** πιστή αναπαραγωγή των 4 αρχών σε CartPole & LunarLander.
- **Επιπλέον:** κριτική αξιολόγηση ανά αρχή/dataset και καινοτόμες επεκτάσεις.

Οι τέσσερις αρχές — σύνοψη

Τέσσερις αρχές σχεδίασης που κάνουν ένα world model φυσικά ερμηνεύσιμο

Αρχή 1	Αρχή 2	Αρχή 3	Αρχή 4
Functionally organized latent space - Χωρισμός του encoder σε ξεχωριστούς κλάδους. - Κάθε κλάδος κωδικοποιεί δικό του υποσύνολο μεγεθών. - Αποσύζευξη φυσικής κατάστασης από visual style.	Aligned invariance & equivariance - Invariance: φωτισμός/χρώμα δεν αλλάζουν το latent. - Equivariance: μετατόπιση/περιστροφή → προβλέψιμη αλλαγή. - Επιβολή μέσω μετασχηματισμών στην είσοδο.	Multi-level / multi-strength supervision - Πλήρης, ασθενής (weak) και ημι-επίβλεψη (semi). - Γνώση μόνο εύρους τιμών ή εκτιμώμενης δυναμικής. - Έλλειψη labels για ταχύτητες.	Output-space partitioning - Πολλαπλοί μικροί decoders (ανά αντικείμενο). - Κατάτμηση (segmentation) της παραγόμενης εικόνας. - Σύνθεση (overlay) στο πλήρες frame.

Dataset Generation & Data Collection

Ασθενής ψευδο-τυχαίος έλεγχος για ομοιόμορφη κάλυψη του state space

CartPole — 4 βαθμοί ελευθερίας

- **State:** $[x, \dot{x}, \theta, \dot{\theta}]$ · 2 διακριτές ενέργειες.
- **Έλεγχος:** PD ελεγκτής στη γωνία ($K\theta=12$, $K\dot{\theta}=2$) + ϵ -greedy ($\epsilon=0.5$).
- **Όγκος:** 5000 επεισόδια $\times \leq 200$ βήματα, frames 80×120 .
- **Θόρυβος state:** noisy_states_2/5/10 σε $x, \theta \rightarrow$ weak supervision.

LunarLander — 8 βαθμοί ελευθερίας

- **State:** $[x, y, v_x, v_y, \theta, \omega, \text{leg1}, \text{leg2}]$ · 4 ενέργειες.
- **Έλεγχος:** PD-like heuristic + ϵ -greedy ($\epsilon=0.2$ — αποφυγή crash).
- **Όγκος:** 4000 επεισόδια $\times \leq 400$ βήματα (πιο σύνθετη 8D κατάσταση).
- **Κοινά:** split 80/10/10, norm_stats μόνο από train (no leakage).

Σκοπός: ομοιόμορφη κάλυψη του state space διατηρώντας λογικές τροχιές — αποφυγή narrow expert behavior και κατάρρευσης από καθαρά τυχαίες ενέργειες.

Μετρικές Αξιολόγησης

Πώς μετράμε εμπειρικά την «ερμηνευσιμότητα» και την προβλεπτική ικανότητα

Ερμηνευσιμότητα κωδικοποίησης

- **Encoder vs GT:** σύγκριση $\mu_{i:N}$ με τα πραγματικά φυσικά states.
- **RMSE / MAE** σε φυσικές μονάδες (de-standardized).
- **R^2 & Pearson r** ανά διάσταση $\rightarrow$ πόσο «καθαρά» χαρτογραφείται κάθε μέγεθος.
- **Scatter & time-series** GT vs encoded $\rightarrow$ tracking, bias, υστέρηση.

Πρόβλεψη, ανακατασκευή & μέγεθος

- **State-MSE ανά horizon:** LSTM rollout vs GT (standardized).
- **Median + IQR** πάνω σε πολλά test windows (robust στατιστική).
- **Paired Δ + 95% bootstrap CI:** στατιστικά σημαντική διαφορά vs baseline.
- **Reconstruction:** MSE & SSIM.
- **Model size:** #παράμετροι (decoder & total).

Αρχιτεκτονικές Επιλογές & Baseline Training

Κοινός κορμός VAE + LSTM για όλες τις αρχές (fair comparison)

VAE — Perception

- Είσοδος 2 διαδοχικά frames (6 κανάλια) → εκτίμηση ταχυτήτων (ill-posed με 1 frame).
- Latent 64: πρώτες N dims supervised με φυσικά states.
- Split- β KL: BETA_PHYS=0.01 σταθερό, beta_style annealed 0→1.

LSTM — Dynamics

- Residual latent predictor (zero-init → ξεκινά ως identity).
- Εκπαίδευση πάνω στα encoded z (όχι GT) — ίδιο domain με inference.
- Teacher forcing scheduled p: 1.0 → 0.3.
- Curriculum horizon: 5 → 30 βήματα.


Baseline

- Ένας μονολιθικός encoder.
- Επίβλεψη μέσω loss στα physical states.
- Ενιαίο, αδιαχώριστο μονοπάτι (unstructured latent).
- Σημείο αναφοράς για κάθε αρχή.

Baseline — Ποιότητα κωδικοποίησης


Encoder vs ground-truth physical states (test set)

CartPole — mean $R^2 = 0.944$



- x, θ σχεδόν τέλεια ($R^2 \approx 0.99$).
- Ταχύτερες δυσκολότερες: $\dot{\theta}$ $R^2=0.84$ — κίνητρο για τις αρχές.

LunarLander — mean $R^2 = 0.892$



- Στατικά (x, y, θ) πολύ καλά ($R^2 > 0.96$).
- Δυσκολότερα: ω ($R^2=0.67$), legs ($R^2 \approx 0.78$) — επαφή/θόρυβος.

Functionally Organized Latent Space

Αρχιτεκτονικός διαχωρισμός του encoding σε δύο ανεξάρτητους κλάδους

Δύο ανεξάρτητοι encoders

- **state_encoder**: 6 κανάλια (2 frames) → N φυσικές dims (βλέπει ταχύτητα).
- **image_encoder**: 3 κανάλια (μόνο frame_t) → style dims.
- **Κλειδί**: ένα frame ΔΕΝ μπορεί να κωδικοποιήσει ταχύτητα → αρχιτεκτονική αποσύζευξη δυναμικής από visual style.
- **Decoder**: κοινός, παίρνει ολόκληρο το latent.


Σχεδιαστικές επιλογές & δυσκολίες

- **Απομόνωση**: ξεχωριστά βάρη + ξεχωριστά $\mu/\log\text{var}$ heads ανά κλάδο.
- **Split- β KL**: οι style dims καταρρέουν προς $N(0,1)$ → καθαρά physical latents για τον LSTM.
- **Έλλειψη paper code**: ανακατασκευή του «stop-gradient» πνεύματος μέσω αρχιτεκτονικού διαχωρισμού.
- **Ablation**: μόνη διαφορά από baseline ο split encoder.


P1 vs Baseline — Prediction MSE

State-MSE ανά horizon, encoded rollout με θορυβώδεις εικόνες ($\sigma=0.1$)

CartPole — βελτίωση 41% (mean) / 61% στο h30



LunarLander — βελτίωση 73% (mean) / 80% στο h30



Γιατί: η δομική απομόνωση προστατεύει τα φυσικά μεγέθη από τον θόρυβο των pixels — μεγαλύτερο όφελος στο πιο σύνθετο LunarLander.

Invariance & Equivariance

Ίδια αρχιτεκτονική με baseline — διαφοροποίηση μόνο στο training objective

Μετασχηματισμοί (στα φυσικά dims)

- **Equivariance θέσης:** object-only μετατόπιση (κάρο+κοντάρι) μέσω segmentation· η ράγα μένει σταθερή.
- **Equivariance γωνίας:** περιστροφή MONO του κονταριού μέσω color-segmentation (tan mask).
- **Invariance φωτεινότητας:** brightness/contrast jitter → latent αμετάβλητο (το παράδειγμα του paper).


Τεχνική & σχεδιαστικές επιλογές

- **Segmentation:** γεωμετρικός/χρωματικός διαχωρισμός αντικειμένου από φόντο.
- **Known h:** γνωστή αλλαγή στο latent (Δx , $\Delta \theta$) στις σωστές standardized μονάδες.
- **Καθαρό ablation:** η real-pair consistency (P3-like) απενεργοποιημένη.
- **LunarLander:** ανάλογοι μετασχηματισμοί στο lander.


P2 vs Baseline — Prediction MSE

Brightness/contrast jitter (level 0.2) στη φάση κωδικοποίησης

CartPole — βελτίωση 38% (mean) / 39% στο h30



LunarLander — βελτίωση 12% (mean) / 27% στο h30



Ανάλυση: οι μετασχηματισμοί κάνουν την κωδικοποίηση πιο σταθερή σε φωτομετρικές αλλαγές → μικρότερο σφάλμα. Το όφελος είναι μικρότερο στο LunarLander (ήδη πιο φωτο-σταθερό).

Multi-Level Supervision

Ίδιος μονολιθικός encoder — αλλάζει μόνο ο στόχος εποπτείας

Ρυθμίσεις εποπτείας

- **SEMI:** επίβλεψη ΜΟΝΟ στα στατικά (θέση/γωνία)· ταχύτητες ανεπίβλεπτες.
- **WEAK:** + εκτίμηση ταχύτητας από φυσική γνώση: finite diff $(x_{t+1} - x_t)/dt$, $dt=0.02$.
- **FULL:** επίβλεψη όλων με αληθινά states $\equiv$ baseline (καμπύλη αναφοράς).


Σχεδιαστικές παρατηρήσεις

- **Standardization:** το finite-diff υπολογίζεται σε raw μονάδες και επανα-standardize-άρεται στις μονάδες της ταχύτητας.
- **2-frame encoder:** η ταχύτητα είναι ήδη παρατηρήσιμη $\rightarrow$ η διαφορά semi vs weak ηπιότερη απ' ό,τι στο paper (single-frame).
- **Συνειδητή επιλογή:** κοινός κορμός με baseline/P1/P2.


Baseline vs Weak vs Semi

State-MSE ανά horizon με θορυβώδεις εικόνες

CartPole ($\sigma=0.05$)



LunarLander ($\sigma=0.03$)



Αιτιολόγηση: στο CartPole το weak $\approx$ baseline ενώ το semi καταρρέει (ταχύτητες κρίσιμες, finite-diff θορυβώδες). Στο πιο σύνθετο LunarLander το weak ΞΕΠΕΡΝΑ το baseline σε μεγάλους ορίζοντες (0.63 vs 1.65) — η ασθενής εποπτεία προσθέτει ανθεκτικότητα στον θόρυβο.

Output-Space Partitioning

Ένας μεγάλος decoder → τρεις μικροί object decoders (overlay)

Compositional decoding



- **3 μικροί decoders:** κάρο, κοντάρι, φόντο — καθένας ανακατασκευάζει το αντικείμενό του.
- **Είσοδος ανά decoder:** υποσύνολο dims (π.χ. cart→[x,ḡ], pole→[x,θ], bg→style).
- **Σύνθεση:** overlay σε λευκό → composite = clamp($\sum$ comp - 2).
- **Encoder:** ίδιος με baseline (P4-only ablation).

Segmentation (κλασική, on-the-fly)

- **Color-segmentation:** bg=λευκό, κάρο=σκούρα pixels, κοντάρι=υπόλοιπα.
- **Strict partition:** κάθε pixel ακριβώς σε μία κλάση → το overlay ανακατασκευάζει το frame.
- **Χωρίς pre-stored masks:** υπολογισμός ανά batch στη GPU.
- **Στόχος:** ίδια ποιότητα με πολύ λιγότερες παραμέτρους decoder.

P4 vs Baseline — Quality vs Model Size

Trade-off ανακατασκευής (MSE / SSIM) έναντι παραμέτρων



CartPole

- -75.4% decoder params · Δ SSIM +0.0001 · Δ MSE -0.00011 (ελαφρώς καλύτερο!).

LunarLander

- -72.3% decoder params · Δ SSIM -0.0028 · Δ MSE +0.00022 (πρακτικά ίδιο).

Συνολική Κριτική Αξιολόγηση των 4 Αρχών

Ποια αρχή είχε τη μεγαλύτερη επίδραση — και πότε χρειάζεται;

Επίδραση ανά αρχή

- **P1 (δομή):** η μεγαλύτερη θετική επίδραση στην πρόβλεψη — έως 73% (LunarLander).
- **P2 (in/equivariance):** σταθερά οφέλη σε φωτομετρικό θόρυβο, μικρότερης κλίμακας.
- **P3 (επίβλεψη):** εξαρτάται από dataset: βοηθά το LunarLander, βλάπτει το semi στο CartPole.
- **P4 (decoding):** ίδια ποιότητα με ~75% λιγότερες decoder-params («free lunch»).

Πρακτικά συμπεράσματα

- **Πολυπλοκότητα:** όσο πιο σύνθετο/θορυβώδες το σύστημα, τόσο μεγαλύτερο το όφελος (LunarLander > CartPole).
- **Όχι πάντα όλες:** οι αρχές δεν είναι πάντα αναγκαίες· P1 & P4 σχεδόν πάντα κερδίζουν.
- **Trade-offs:** P3 μπορεί να βλάψει όταν η εκτίμηση δυναμικής είναι θορυβώδης.
- **Ερμηνευσιμότητα ≠ κόστος:** συχνά συνοδεύεται από καλύτερη ανθεκτικότητα.

Δυναμική Χωρίς Νευρωνικά — SINDy

Sparse Identification of Nonlinear Dynamics

[Διαφάνεια προς συμπλήρωση]

- Αντικατάσταση του black-box LSTM με SINDy για εύρεση διαφορικών εξισώσεων.
- Σύγκριση SINDy vs LSTM & υβριδικές προσεγγίσεις (horizon-gated, Kalman).
- (Κώδικες: `sindy*.py`, `fusion_*.py` — θα συμπληρωθεί σε επόμενο βήμα.)

Έλεγχος & Βελτιστοποίηση (Control)

Σύνδεση ερμηνευσιμότητας με actual control policy

[Διαφάνεια προς συμπλήρωση]

- Σύγκριση κλασικού PID με υβριδικό PID-MPC.
- Αξιοποίηση του «ονείρου» (dreaming) του World Model για πρόβλεψη μελλοντικών αστοχιών.
- (Κώδικες: extension4_control*.py — θα συμπληρωθεί σε επόμενο βήμα.)

Robustness & Out-of-Distribution Testing

Ανθεκτικότητα σε θόρυβο/spikes στα static states

[Διαφάνεια προς συμπλήρωση]

- Εισαγωγή θορύβου στα states κατά το evaluation phase.
- Στόχος: τα PIWM πιο ανθεκτικά σε OOD/sensor noise από το baseline.
- (Θα συμπληρωθεί σε επόμενο βήμα.)

Κατανομή Εργασιών (Team Contributions)

Ποιος ανέλαβε τι

[Διαφάνεια προς συμπλήρωση]

- Πίνακας με ονοματεπώνυμο κάθε μέλους και tasks (Κώδικας, Εκπαίδευση, Πειράματα, Παρουσίαση).
- (Θα συμπληρωθεί σε επόμενο βήμα.)

Retrospective

Τι μάθαμε από τη διαδικασία

[Διαφάνεια προς συμπλήρωση]

- Δυσκολίες: υπολογιστικοί πόροι, συνεργασία, bugs από έλλειψη open-source κώδικα στο paper.
- Βελτιώσεις: time management, code architecture, communication.
- (Θα συμπληρωθεί σε επόμενο βήμα.)